

Chapitre 3 : FACTORISATION QR ET SYSTÈMES SURDÉTERMINÉS

1 Factorisation QR

- Factorisation QR : généralités
- Méthode de Householder : principe
- Transformation de Householder
- Factorisation QR : exemple
- Factorisation QR : algorithme

2 Systèmes surdéterminés

- Interlude : propriétés de la norme euclidienne
- Systèmes surdéterminés : généralités
- Systèmes surdéterminés : solution formelle
- Interprétation géométrique
- Equations normales
- Conditionnement
- Méthode des équations normales (version LU)
- Méthode de la factorisation QR
- Comparaison des méthodes : exemple
- Annexe : conditionnement

FACTORISATION QR : GÉNÉRALITÉS

Une matrice Q est **orthogonale** si elle est carrée et $Q^T Q = I$.

Une matrice $R = (r_{ij})$ est **trapézoïdale supérieure** si $r_{ij} = 0$ pour tout $i > j$.

Une factorisation QR d'une matrice A (instruction `qr(A)`) de dimensions $m \times n$ ($m \geq n$) est une combinaison des matrices Q orthogonale (de dimensions $m \times m$) et R trapézoïdale supérieure (de dimensions $m \times n$) telles que

$$A = QR.$$

Comme les $m - n$ dernières lignes de R sont nulles, on a

$$R = \begin{pmatrix} \hat{R} \\ 0 \end{pmatrix}, \quad \text{avec } \hat{R} \text{ de dimensions } n \times n,$$

et en subdivisant $Q = (\hat{Q} \ \hat{Q}_\perp)$ avec \hat{Q} de dimensions $m \times n$ on a aussi une factorisation QR réduite (instruction `qr(A, 0)`)


$$A = \hat{Q}\hat{R}.$$

EXEMPLE :
 $(m = 10, n = 5)$

$$\begin{matrix} * & * & * & * & * \\ * & * & * & * & * \\ * & * & * & * & * \\ * & * & * & * & * \\ * & * & * & * & * \\ * & * & * & * & * \\ * & * & * & * & * \\ * & * & * & * & * \\ * & * & * & * & * \\ * & * & * & * & * \end{matrix} A = \begin{matrix} * & * & * & * & * \\ * & * & * & * & * \\ * & * & * & * & * \\ * & * & * & * & * \\ * & * & * & * & * \\ * & * & * & * & * \\ * & * & * & * & * \\ * & * & * & * & * \\ * & * & * & * & * \\ * & * & * & * & * \end{matrix} Q \begin{matrix} * & * & * & * & * \\ * & * & * & * & * \\ * & * & * & * & * \\ * & * & * & * & * \\ * & * & * & * & * \\ * & * & * & * & * \\ * & * & * & * & * \\ * & * & * & * & * \\ * & * & * & * & * \\ * & * & * & * & * \end{matrix} R = \begin{matrix} * & * & * & * & * \\ * & * & * & * & * \\ * & * & * & * & * \\ * & * & * & * & * \\ * & * & * & * & * \\ * & * & * & * & * \\ * & * & * & * & * \\ * & * & * & * & * \\ * & * & * & * & * \\ * & * & * & * & * \end{matrix} Q \begin{matrix} * & * & * & * & * \\ * & * & * & * & * \\ * & * & * & * & * \\ * & * & * & * & * \\ * & * & * & * & * \\ * & * & * & * & * \\ * & * & * & * & * \\ * & * & * & * & * \\ * & * & * & * & * \\ * & * & * & * & * \end{matrix} R$$

MÉTHODE DE HOUSEHOLDER : PRINCIPE

PRINCIPE DE BASE :



Si Q_i , $i = 1, \dots, 5$, sont des matrices orthogonales symétriques, alors

$$Q = Q_1 \cdots Q_5$$

et

$$Q^T = Q_5 \cdots Q_1$$

sont également orthogonales (pourquoi ? et symétriques ?).

D'autre part $R = Q_5 \cdots Q_1A = Q^TA$ est bien trapézoïdale supérieure.

On a donc bien une factorisation

$$A = QR.$$

TRANSFORMATION DE HOUSEHOLDER

Une manière d'obtenir la factorisation QR est d'utiliser la transformation de Householder, définie pour un vecteur $\mathbf{v} = (v_i)$ comme

$$H = I - 2 \frac{\mathbf{v}\mathbf{v}^T}{\|\mathbf{v}\|_2^2}.$$

La transformation est :

- symétrique

$$(\mathbf{v}\mathbf{v}^T)^T = \mathbf{v}\mathbf{v}^T;$$

et donc H est combinaison linéaire de matrices symétriques ;

- orthogonale

$$\text{car } H^T H = HH = I - 4 \frac{\mathbf{v}\mathbf{v}^T}{\|\mathbf{v}\|_2^2} + 4 \frac{\mathbf{v}(\mathbf{v}^T \mathbf{v}) \mathbf{v}^T}{\|\mathbf{v}\|_2^4} = I;$$

TRANSFORMATION DE HOUSEHOLDER

Une manière d'obtenir la factorisation QR est d'utiliser la transformation de Householder, définie pour un vecteur $\mathbf{v} = (v_i)$ comme

$$H = I - 2 \frac{\mathbf{v}\mathbf{v}^T}{\|\mathbf{v}\|_2^2}.$$

La transformation permet de :

- introduire des zéros

pour un vecteur $\mathbf{x} = (x_i)$ donné on choisit $\mathbf{v} = \mathbf{x} \pm \|\mathbf{x}\|_2 \mathbf{e}_j$ où \mathbf{e}_j est le j ème vecteur de la base canonique ; alors

$$H\mathbf{x} = \mp \|\mathbf{x}\|_2 \mathbf{e}_j.$$

En effet, $2\mathbf{v}^T \mathbf{x} = 2\|\mathbf{x}\|_2^2 \pm 2\|\mathbf{x}\|_2 x_j = \|\mathbf{v}\|_2^2$ et donc

$$H\mathbf{x} = \mathbf{x} - 2 \frac{\mathbf{v}\mathbf{v}^T}{\|\mathbf{v}\|_2^2} \mathbf{x} = \mathbf{x} - \mathbf{v} = \mp \|\mathbf{x}\|_2 \mathbf{e}_j.$$

NOTE : Pour éviter le phénomène d'annulation on choisit le signe qui mène à l'addition de deux nombres de même signe ; en l'occurrence $\mathbf{v} = \mathbf{x} + \text{signe}(x_j) \|\mathbf{x}\|_2 \mathbf{e}_j$.

FACTORIZATION QR : EXEMPLE

EXAMPLE :

$$\left(\begin{array}{cccc} 1 & 1 & 1 & 1 \\ 1 & 2 & 4 & 8 \\ 1 & 3 & 9 & 27 \\ 1 & 5 & 25 & 125 \\ 1 & 6 & 36 & 216 \\ 1 & 7 & 49 & 343 \end{array} \right) \text{ avec } \mathbf{v}^{(1)} = \left(\begin{array}{c} 1 + \sqrt{6} \\ 1 \\ 1 \\ 1 \\ 1 \\ 1 \end{array} \right) \text{ et } Q_1 := I - 2 \frac{\mathbf{v}^{(1)} \mathbf{v}^{(1)T}}{\|\mathbf{v}^{(1)}\|_2^2}$$

$$\rightarrow Q_1 A = \left(\begin{array}{cccc} -\sqrt{6} & -9.7... & -50.6... & -293.9... \\ -1.1... & -10.9... & -77.5... & \\ -0.1... & -5.9... & -58.5... & \\ 1.8... & 10.0... & -39.4... & \\ 2.8... & 21.0... & 130.5... & \\ 3.8... & 34.0... & 257.5... & \end{array} \right)$$

FACTORISATION QR : EXEMPLE

EXEMPLE :

$$\left(\begin{array}{cccc} 1 & 1 & 1 & 1 \\ 1 & 2 & 4 & 8 \\ 1 & 3 & 9 & 27 \\ 1 & 5 & 25 & 125 \\ 1 & 6 & 36 & 216 \\ 1 & 7 & 49 & 343 \end{array} \right) \text{ avec } \mathbf{v}^{(1)} = \left(\begin{array}{c} 1 + \sqrt{6} \\ 1 \\ 1 \\ 1 \\ 1 \\ 1 \end{array} \right) \text{ et } Q_1 := I - 2 \frac{\mathbf{v}^{(1)} \mathbf{v}^{(1)T}}{\|\mathbf{v}^{(1)}\|_2^2}$$

$$\rightarrow Q_1 A = \left(\begin{array}{ccccc} -\sqrt{6} & \boxed{-9.7...} & -50.6... & -293.9... & \\ & -1.1... & -10.9... & -77.5... & \\ & -0.1... & -5.9... & -58.5... & \\ & 1.8... & 10.0... & -39.4... & \\ & 2.8... & 21.0... & 130.5... & \\ & 3.8... & 34.0... & 257.5... & \end{array} \right) \text{ avec } \mathbf{v}^{(2)} = \left(\begin{array}{c} -9.7... \\ -1.1... \\ -0.1... \\ 1.8... \\ 2.8... \\ 3.8... \end{array} \right)$$

$$\text{et } Q_2 := I - 2 \frac{\mathbf{v}^{(2)} \mathbf{v}^{(2)T}}{\|\mathbf{v}^{(2)}\|_2^2} \rightarrow Q_2 Q_1 A = \left(\begin{array}{ccccc} -0.7... & 9.7... & 55.0... & & \\ 2.1... & 11.1... & 61.6... & 399.9... & \\ 0.02... & -5.1... & -53.4... & & \\ -0.3... & -1.4... & -32.8... & & \\ -0.5... & 3.3... & 19.5... & & \\ -0.6... & 10.1... & 107.8... & & \end{array} \right)$$

→ ce n'est pas ce qu'on voulait...

FACTORIZATION QR : EXEMPLE

EXEMPLE :

$$\left(\begin{array}{cccc} 1 & 1 & 1 & 1 \\ 1 & 2 & 4 & 8 \\ 1 & 3 & 9 & 27 \\ 1 & 5 & 25 & 125 \\ 1 & 6 & 36 & 216 \\ 1 & 7 & 49 & 343 \end{array} \right) \text{ avec } \mathbf{v}^{(1)} = \begin{pmatrix} 1 + \sqrt{6} \\ 1 \\ 1 \\ 1 \\ 1 \\ 1 \end{pmatrix} \text{ et } Q_1 := I - 2 \frac{\mathbf{v}^{(1)} \mathbf{v}^{(1)T}}{\|\mathbf{v}^{(1)}\|_2^2}$$

$$\rightarrow Q_1 A = \begin{pmatrix} -\sqrt{6} & \begin{matrix} -9.7... & -50.6... & -293.9... \\ -1.1... & -10.9... & -77.5... \\ -0.1... & -5.9... & -58.5... \\ 1.8... & 10.0... & -39.4... \\ 2.8... & 21.0... & 130.5... \\ 3.8... & 34.0... & 257.5... \end{matrix} \end{pmatrix} \text{ avec } \mathbf{v}^{(2)} = \begin{pmatrix} -9.7... \\ -1.1... \\ -0.1... \\ 1.8... \\ 2.8... \\ 3.8... \end{pmatrix}$$

$$\text{et } Q_2 := I - 2 \frac{\mathbf{v}^{(2)} \mathbf{v}^{(2)T}}{\|\mathbf{v}^{(2)}\|_2^2} \rightarrow Q_2 Q_1 A = \begin{pmatrix} -0.7... & 9.7... & 85.0... \\ 2.1... & 11.1... & 64.6... & 396.9... \\ 0.02... & -5.1... & -53.4... \\ -0.3... & -1.4... & -32.8... \\ -0.5... & 3.3... & 19.5... \\ -0.6... & 10.1... & 107.8... \end{pmatrix}$$

→ ce n'est pas ce qu'on voulait...

FACTORIZATION QR : EXEMPLE

EXAMPLE :

$$\left(\begin{array}{cccc} 1 & 1 & 1 & 1 \\ 1 & 2 & 4 & 8 \\ 1 & 3 & 9 & 27 \\ 1 & 5 & 25 & 125 \\ 1 & 6 & 36 & 216 \\ 1 & 7 & 49 & 343 \end{array} \right) \text{ avec } \mathbf{v}^{(1)} = \left(\begin{array}{c} 1 + \sqrt{6} \\ 1 \\ 1 \\ 1 \\ 1 \\ 1 \end{array} \right) \text{ et } Q_1 := I - 2 \frac{\mathbf{v}^{(1)} \mathbf{v}^{(1)T}}{\|\mathbf{v}^{(1)}\|_2^2}$$

$$\rightarrow Q_1 A = \left(\begin{array}{ccccc} -\sqrt{6} & -9.7... & -50.6... & -293.9... & \\ \boxed{-1.1...} & -10.9... & -77.5... & & \\ -0.1... & -5.9... & -58.5... & & \\ 1.8... & 10.0... & -39.4... & & \\ 2.8... & 21.0... & 130.5... & & \\ 3.8... & 34.0... & 257.5... & & \end{array} \right) \text{ avec } \mathbf{v}^{(2)} = \left(\begin{array}{c} -1.1... - 5.2... \\ -0.1... \\ 1.8... \\ 2.8... \\ 3.8... \end{array} \right)$$

$$\text{et } Q_2 := \left(\begin{array}{cc} 1 & \\ & I - 2 \frac{\mathbf{v}^{(2)} \mathbf{v}^{(2)T}}{\|\mathbf{v}^{(2)}\|_2^2} \end{array} \right) \rightarrow Q_2 Q_1 A = \left(\begin{array}{ccccc} -\sqrt{6} & -9.7... & -50.6... & -293.9... & \\ 5.2... & 42.3... & 291.0... & & \\ -4.8... & -51.0... & & & \\ -5.4... & -67.8... & & & \\ -2.7... & -34.1... & & & \\ 1.9... & 35.4... & & & \end{array} \right)$$

FACTORISATION QR : ALGORITHME

L'algorithme retourne R et une séquence des vecteurs $\mathbf{v}^{(1)}, \dots, \mathbf{v}^{(n)}$ (laquelle définit Q implicitement)

ALGORITHME (QR DE HOUSEHOLDER) :

$R = A$

pour $k = 1, \dots, n$

$\mathbf{x} = R(k : m, k)$ % vecteur de composantes k à m de la colonne k de R

$\mathbf{v}^{(k)} = \mathbf{x} + \text{sign}(x_1) \|\mathbf{x}\|_2 \mathbf{e}_1$

$\mathbf{v}^{(k)} = \mathbf{v}^{(k)} / \|\mathbf{v}^{(k)}\|_2$ % normaliser $\mathbf{v}^{(k)}$

% multiplier $I - 2\mathbf{v}^{(k)} \mathbf{v}^{(k)T}$ avec $R(k : m, k : n)$

% coût de l'application $\approx 4(m - k + 1)(n - k + 1)$

$R(k : m, k : n) = R(k : m, k : n) - \mathbf{v}^{(k)} (2(\mathbf{v}^{(k)T} R(k : m, k : n)))$

COÛT : $\sum_{k=1}^n (\underbrace{\text{coût dernière ligne algorithme}}_{4(m-k+1)(n-k+1) \text{ flops}} + \mathcal{O}(mn)) = 2n^2(m-n/3) + \mathcal{O}(mn)$ flops

FACTORISATION QR : ALGORITHME (SUITE)

L'algorithme précédent ne forme pas la matrice

$$Q = Q_1 \cdots Q_n$$

explicitement ; elle est connue implicitement via les vecteurs $\mathbf{v}^{(1)}, \dots, \mathbf{v}^{(n)}$. Dans certains cas, seul le produit de Q avec un vecteur de dimension m (disons \mathbf{w}) est nécessaire.

ALGORITHME $\mathbf{w} := Q\mathbf{w} :$

pour $k = n, \dots, 1$

$$\mathbf{w}(k : m) := \mathbf{w}(k : m) - \mathbf{v}^{(k)} (2 \mathbf{v}^{(k)} {}^T \mathbf{w}(k : m))$$

Coût : $\sum_{k=1}^n 4(m-k+1)$

$$= 2n(2m-n+1)$$

Le produit $Q^T \mathbf{w} = Q_n \cdots Q_1 \mathbf{w}$ est similaire.

ALGORITHME $\mathbf{w} := Q^T \mathbf{w} :$

pour $k = 1, \dots, n$

$$\mathbf{w}(k : m) := \mathbf{w}(k : m) - \mathbf{v}^{(k)} (2 \mathbf{v}^{(k)} {}^T \mathbf{w}(k : m))$$

Coût : $\sum_{k=1}^n 4(m-k+1)$

$$= 2n(2m-n+1)$$

FACTORISATION QR : ALGORITHME (SUITE)

Comme

$$Q = (\hat{Q} \ *)$$

avec \hat{Q} une matrice $m \times n$, on peut utiliser les algorithmes précédents pour évaluer le produit de \hat{Q} avec un vecteur $\hat{\mathbf{w}}$ de dimension n via

$$\hat{Q}\hat{\mathbf{w}} = Q \begin{pmatrix} \hat{\mathbf{w}} \\ * \end{pmatrix};$$

de manière similaire, le produit \hat{Q}^T avec un vecteur \mathbf{w} de dimension m s'obtient avec

$$\begin{pmatrix} \hat{Q}^T \mathbf{w} \\ * \end{pmatrix} = Q^T \mathbf{w};$$

Finalement, les matrices Q et \hat{Q} peuvent aussi être formées explicitement, leur j ème colonne étant $Q\mathbf{e}_j$.

EXEMPLE P.2 :
 $(m = 10, n = 5)$

$$\begin{matrix} \text{A} \\ \begin{matrix} \text{A} & \text{B} & \text{C} & \text{D} & \text{E} \end{matrix} \end{matrix} = \begin{matrix} \text{Q} \\ \begin{matrix} \text{Q} & \text{R} \end{matrix} \end{matrix} = \begin{matrix} \text{R} \\ \begin{matrix} \text{R} & \text{Q} \end{matrix} \end{matrix} = \begin{matrix} \text{Q} \\ \text{Q} \end{matrix} \begin{matrix} \text{H} \\ \text{H} \end{matrix}$$

INTERLUDE : PROPRIÉTÉS DE LA NORME EUCLIDIENNE

PROPRIÉTÉ 1 : soient A une matrice symétrique et $\lambda_i, i = 1, \dots, n$, ses valeurs propres. Alors

$$\|A\|_2 = \max_i |\lambda_i| = \max_{\mathbf{v}} \frac{|\mathbf{v}^T A \mathbf{v}|}{\mathbf{v}^T \mathbf{v}}.$$

Soit \mathbf{p}_i le vecteur propre normalisé associé à $\lambda_i, i = 1, \dots, n$. Comme la matrice A est symétrique, l'ensemble de ces vecteurs forment une base orthonormale et tout vecteur \mathbf{v} a une représentation $\mathbf{v} = \sum_{i=1}^n \alpha_i \mathbf{p}_i$ dans cette base. On a alors

$$\|A\|_2^2 = \max_{\mathbf{v}} \frac{\|A\mathbf{v}\|_2^2}{\|\mathbf{v}\|_2^2} = \max_{\mathbf{v}} \frac{\mathbf{v}^T A^2 \mathbf{v}}{\mathbf{v}^T \mathbf{v}} = \max_{\alpha_1, \dots, \alpha_n} \frac{\sum_{i=1}^n \lambda_i^2 \alpha_i^2}{\sum_{i=1}^n \alpha_i^2} = \max_i |\lambda_i|^2.$$

Par analogie avec les deux dernières égalités on a aussi

$$\max_{\mathbf{v}} \frac{|\mathbf{v}^T A \mathbf{v}|}{\mathbf{v}^T \mathbf{v}} = \max_{\alpha_1, \dots, \alpha_n} \frac{|\sum_{i=1}^n \lambda_i \alpha_i^2|}{\sum_{i=1}^n \alpha_i^2} = \max_i |\lambda_i|.$$

PROPRIÉTÉ 2 : pour toute matrice A rectangulaire

$$\|A^T A\|_2 = \|A\|_2^2.$$

$$\|A^T A\|_2 = \max_{\mathbf{v}} \frac{|\mathbf{v}^T A^T A \mathbf{v}|}{\mathbf{v}^T \mathbf{v}} = \max_{\mathbf{v}} \frac{\|A\mathbf{v}\|_2^2}{\|\mathbf{v}\|_2^2}.$$

INTERLUDE : PROPRIÉTÉS DE LA NORME EUCLIDIENNE

PROPRIÉTÉ 3 : pour toute matrice A rectangulaire

$$\|A^T\|_2 = \|A\|_2.$$

Considérons d'abord le cas particulier d'un vecteur \mathbf{w} . En notant avec θ l'angle entre les vecteurs \mathbf{w} et \mathbf{v} , on a

$$\|\mathbf{w}^T\|_2 = \max_{\mathbf{v}} \frac{|\mathbf{w}^T \mathbf{v}|}{\|\mathbf{v}\|_2} = \max_{\theta} \frac{\|\mathbf{w}\|_2 \|\mathbf{v}\|_2 |\cos(\theta)|}{\|\mathbf{v}\|_2} = \|\mathbf{w}\|_2.$$

Maintenant, comme pour deux matrices A , B la norme du produit satisfait

$$\|AB\|_2 \leq \|A\|_2 \|B\|_2,$$

on a

$$\|A^T\|_2 = \max_{\mathbf{v}} \frac{\|A^T \mathbf{v}\|_2}{\|\mathbf{v}\|_2} = \max_{\mathbf{v}} \frac{\|\mathbf{v}^T A\|_2}{\|\mathbf{v}^T\|_2} \leq \max_{\mathbf{v}} \frac{\|\mathbf{v}^T\|_2 \|A\|_2}{\|\mathbf{v}^T\|_2} = \|A\|_2.$$

En même temps $A = A^{T^T}$ et donc $\|A\|_2 \leq \|A^T\|_2$, d'où l'égalité.

SYSTÈMES SURDÉTERMINÉS : GÉNÉRALITÉS

On considère les systèmes surdéterminés

$$\left\{ \begin{array}{l} a_{11}x_1 + \cdots + a_{1n}x_n = b_1 \\ a_{21}x_1 + \cdots + a_{2n}x_n = b_2 \\ \vdots \\ a_{m1}x_1 + \cdots + a_{mn}x_n = b_m \end{array} \right.$$

avec

- au moins autant d'équations que d'inconnues ($m \geq n$)
- le rang maximal (la matrice du système est de rang n).

Sous forme matricielle :

$$A\mathbf{x} = \mathbf{b}.$$

En règle générale, le système n'a pas de solution, et donc, le résidu

$$\mathbf{r} = \mathbf{b} - A\mathbf{x}$$

n'est pas nul. On parle alors de la solution \mathbf{x} au sens des moindres carrés si elle minimise la norme euclidienne du résidu ; c'est-à-dire si

$$\|\mathbf{b} - A\mathbf{x}\|_2 = \min_{\mathbf{y}} \|\mathbf{b} - A\mathbf{y}\|_2.$$

SYSTÈMES SURDÉTERMINÉS : SOLUTION FORMELLE

On procède en deux étapes.

- ① On détermine les points critiques de

$$f(\mathbf{x}) = \|\mathbf{b} - A\mathbf{x}\|_2^2,$$

c'est-à-dire tous les \mathbf{x} tels que $\nabla f(\mathbf{x}) = 0$, ou encore


$$\boxed{A^T A \mathbf{x} = A^T \mathbf{b}}. \quad (1)$$

C'est le système d'**équations normales**. Si le rang de A est maximal (égal à n), alors le rang de $A^T A$ est maximal (égal à n) et $A^T A$ est inversible ; en particulier, il y a un et un seul point critique.

- ② On montre que ce \mathbf{x} minimise bien f (et minimise globalement !) :

$$\begin{aligned} \|\mathbf{b} - A\mathbf{y}\|_2^2 &= \|\mathbf{b} - A\mathbf{x} + A(\mathbf{x} - \mathbf{y})\|_2^2 \\ &= \|\mathbf{b} - A\mathbf{x}\|_2^2 + 2(\mathbf{x} - \mathbf{y})^T \underbrace{A^T(\mathbf{b} - A\mathbf{x})}_{=0} + \underbrace{\|A(\mathbf{x} - \mathbf{y})\|_2^2}_{\geq 0} \\ &\geq \|\mathbf{b} - A\mathbf{x}\|_2^2. \end{aligned}$$

INTERPRÉTATION GÉOMÉTRIQUE



Une autre manière d'interpréter la solution :

$\mathbf{r} = \mathbf{b} - A\mathbf{x}$ est minimisé si il est orthogonal à $A\mathbf{w}$ pour tout $\mathbf{w} \in \mathbb{R}^n$;

et donc si

$$A^T \mathbf{r} = A^T(\mathbf{b} - A\mathbf{x}) = \mathbf{0}.$$

L'angle θ entre le vecteur \mathbf{b} et l'hyperplan $A\mathbf{w}$, $\mathbf{w} \in \mathbb{R}^n$ mesure la capacité de $A\mathbf{x}$ à approcher \mathbf{b} .

Si \mathbf{r} est le résidu minimal, alors

$$\sin(\theta) = \frac{\|\mathbf{r}\|_2}{\|\mathbf{b}\|_2}.$$

EQUATIONS NORMALES

La résolution au sens des moindres carrés est donc équivalente à

$$\boxed{A^T A \mathbf{x} = A^T \mathbf{b}}. \quad (1)$$

La matrice $A^T A$ du système est :

- symétrique, car

$$(A^T A)^T = A^T A$$

- définie positive, car

$$\mathbf{v}^T A^T A \mathbf{v} = \|A\mathbf{v}\|_2^2 \geq 0$$

et

$$\mathbf{v}^T A^T A \mathbf{v} = 0 \Leftrightarrow A\mathbf{v} = \mathbf{0} \xrightarrow{\text{A de rang maximal}} \mathbf{v} = \mathbf{0}.$$

RAPPEL : une matrice M est définie positive si pour tout $\mathbf{v} \neq \mathbf{0}$ on a

$$\mathbf{v}^T M \mathbf{v} > 0.$$

CONDITIONNEMENT MATRICIEL : GÉNÉRALISATION

La résolution au sens des moindres carrés est donc équivalente à

$$A^T A \mathbf{x} = A^T \mathbf{b}. \quad (1)$$

Pour une matrice A régulière, le conditionnement (en norme 2) est défini par

$$\kappa(A) = \|A^{-1}\| \|A\|.$$

Si le nombre de lignes est supérieur au nombre de colonnes, la matrice A n'est pas inversible ; néanmoins, si $\text{rang}(A) = n$, elle possède un pseudo-inverse

$$A^\dagger = (A^T A)^{-1} A^T;$$

notez que la solution de (1) est $\mathbf{x} = A^\dagger \mathbf{b}$. Le conditionnement de A (en norme euclidienne) est alors défini par

$$\kappa(A) = \|A^\dagger\|_2 \|A\|_2.$$

Pour ce qui est du pseudo-inverse, l'identité suivante nous sera utile

$$\|(A^T A)^{-1}\|_2 = \|A^\dagger A^{\dagger T}\|_2 = \|A^{\dagger T}\|_2^2 = \|A^\dagger\|_2^2. \quad (2)$$

SYSTÈMES SURDÉTERMINÉS : CONDITIONNEMENT

La résolution au sens des moindres carrés est donc équivalente à

$$A^T A \mathbf{x} = A^T \mathbf{b}.$$

Le conditionnement d'un problème est

$$\kappa = \sup \frac{\text{erreurs relatives résultat}}{\text{erreurs relatives données}},$$

avec les erreurs données $\rightarrow 0$.

Pour un problème aux moindres carrés :

- données : A , \mathbf{b} (avec perturbations $A + \delta A$, $\mathbf{b} + \delta \mathbf{b}$)
- résultat : \mathbf{x} ($\mathbf{x} + \delta \mathbf{x}$ pour le système perturbé)

SYSTÈMES SURDÉTERMINÉS : CONDITIONNEMENT

La résolution au sens des moindres carrés est donc équivalente à

$$A^T A \mathbf{x} = A^T \mathbf{b}.$$

Le conditionnement d'un problème est

$$\kappa = \sup \frac{\text{erreurs relatives résultat}}{\text{erreurs relatives données}},$$

avec les erreurs données $\rightarrow 0$.


On peut montrer (cf. Annexe) que

$$\text{pour erreurs } \delta A \text{ sur } A : \kappa_{MC,A} \leq \kappa(A) + \frac{\kappa(A)^2 \|\mathbf{r}\|_2}{\|A\|_2 \|\mathbf{x}\|_2} \leq \kappa(A) + \kappa(A)^2 \tan(\theta)$$

$$\text{pour erreurs } \delta \mathbf{b} \text{ sur } \mathbf{b} : \kappa_{MC,\mathbf{b}} \leq \kappa(A) / \cos(\theta)$$

CONCLUSION :

- $\theta \approx 0 \Rightarrow \kappa_{MC,A} \approx \kappa_{MC,\mathbf{b}} \approx \kappa(A)$
- $0 \ll \theta \ll \frac{\pi}{2} \Rightarrow \kappa_{MC,A} \approx \kappa(A)^2$
 $\kappa_{MC,\mathbf{b}} \approx \kappa(A)$
- $\theta \rightarrow \frac{\pi}{2} \Rightarrow \kappa_{MC,A}, \kappa_{MC,\mathbf{b}} \rightarrow \infty$ (car $\mathbf{x} \approx \mathbf{0}$)



MÉTHODE DES ÉQUATIONS NORMALES (VERSION LU)

La méthode consiste à former le système

$$A^T A \mathbf{x} = A^T \mathbf{b} \quad (1)$$

explicitement et en calculer sa factorisation LU avec pivotage.

ALGORITHME :

- ➊ former $A^T A$, $A^T \mathbf{b}$ ($\approx mn^2$ (symétrie) + $2mn$ flops)
- ➋ calculer la factorisation LU avec piv. $LU = P(A^T A)$ ($\approx 2n^3/3$ flops)
- ➌ résoudre $L\mathbf{y} = P(A^T \mathbf{b})$ et $U\mathbf{x} = \mathbf{y}$ ($\approx 2n^2$ flops)

- dans la situation (habituelle) où $m \gg n$ le coût est dominé par mn^2
- le conditionnement du système (1) est (en utilisant (2) et Propriété 2)

$$\kappa(A^T A) = \|(A^T A)^{-1}\|_2 \|A^T A\|_2 = \|A^\dagger\|_2^2 \|A\|_2^2 = \kappa(A)^2;$$

pour rappel, si l'angle θ entre \mathbf{b} et $A\mathbf{x}$ est proche de 0 , $\kappa_{MC,A} \approx \kappa(A)$ et une perte de précision est possible si on utilise cette méthode lorsque la matrice est mal conditionnée (c'est-à-dire si $\kappa(A) \gg 1$) ; dans ce cas la méthode est **instable**.

MÉTHODE DE LA FACTORISATION QR

La méthode utilise la factorisation $\hat{Q}\hat{R}$ réduite de A ; elle est basée sur le fait que la solution \mathbf{x} du système

$$A^T A \mathbf{x} = A^T \mathbf{b}$$

satisfait aussi

$$\mathbf{x} = (A^T A)^{-1} A^T \mathbf{b} = (\hat{R}^T \cancel{\hat{Q}}^T \cancel{Q} \hat{R})^{-1} \hat{R}^T \cancel{\hat{Q}}^T \mathbf{b} = \hat{R}^{-1} \cancel{\hat{R}^T} \hat{R}^T \hat{Q}^T \mathbf{b} = \hat{R}^{-1} \hat{Q}^T \mathbf{b};$$

ALGORITHME :


- ❶ calculer la factorisation $\hat{Q}\hat{R} = A$ ($\approx 2n^2(m - n/3)$ flops)
- ❷ former $\hat{Q}^T \mathbf{b}$ ($\approx 4mn$ flops)
- ❸ résoudre $\hat{R}\mathbf{x} = \hat{Q}^T \mathbf{b}$ ($\approx n^2$ flops)

- $A^T A$ ne doit pas être formée;
- dans la situation (habituelle) où $m \gg n$ le coût est dominé par $2mn^2$
- si la factorisation $\hat{Q}\hat{R}$ réduite est bien calculée par la méthode de Householder, le présent algorithme a la stabilité inverse

COMPARAISON DES MÉTHODES : EXEMPLE

EXEMPLE¹ : interpolation de la fonction $\exp(\sin(4*t))$ aux points repartis uniformément sur l'intervalle $[0, 1]$ par un polynôme de degré 14

```
m = 100; n = 15;
t = 0:1/(m-1):1; t = t';
A = [];
for i=1:n
    A = [A t.^^(i-1)];
end
b = exp(sin(4*t));
% valeur exacte de x(15)
% obtenue via des outils
% de précision étendue
x15ex = 2006.787453080206
```



1. Repris de L. N. Trefethen, D. Bau, *Numerical Linear Algebra*, SIAM, Philadelphia, PA, 1997

COMPARAISON DES MÉTHODES : EXEMPLE

EXEMPLE¹ : interpolation de la fonction `exp(sin(4*t))` aux points repartis uniformément sur l'intervalle `[0, 1]` par un polynôme de degré 14

Instruction Octave

```
x = A\b;  
x(15)/x15ex
```

ans = 1.00000007318865

Méthode QR (Householder)

```
[Q, R] = qr(A, 0);  
x = R\((Q'*b);  
x(15)/x15ex
```

ans = 1.00000007318102

Méthode équations normales (version LU)

```
[L U P] = lu(A'*A);  
x = U\((L\((P*(A'*b))));  
x(15)/x15ex
```

ans = 1.56194368637586

1. Repris de L. N. Trefethen, D. Bau, *Numerical Linear Algebra*, SIAM, Philadelphia, PA, 1997

COMPARAISON DES MÉTHODES : EXEMPLE

EXEMPLE¹ : interpolation de la fonction `exp(sin(4*t))` aux points repartis uniformément sur l'intervalle `[0, 1]` par un polynôme de degré **14**

EXPLICATION : pour ce problème

- $\kappa_{MC,A} \leq 3.2 \cdot 10^{10}$
- $\kappa_{MC,b} \leq 2.3 \cdot 10^{10}$

et donc en double précision une méthode qui a la stabilité directe doit fournir un résultat avec une précision relative d'environ $u\kappa_{MC} \approx 10^{-6}$. Par contre

- $\kappa(A)^2 = 2.3 \cdot 10^{20}$.

et donc la réponse obtenue par la méthode des équations normales risque de ne pas être (et n'est en effet pas !) précise.

```
kA = cond(A)
x=A\b; r = A*x-b;
theta = asin(norm(r)/norm(b));
c = norm(r)/norm(A)/norm(x);
K_MCA_max = kA + kA^2 * c
K_MCB_max = kA/cos(theta)
```

K_MCA_max = 3.1909e+10
K_MCB_max = 2.2718e+10

1. Repris de L. N. Trefethen, D. Bau, *Numerical Linear Algebra*, SIAM, Philadelphia, PA, 1997

ANNEXE : CONDITIONNEMENT (DÉRIVATION)

Le problème aux moindres carrés est équivalent à

$$A^T A \mathbf{x} = A^T \mathbf{b}.$$

Le conditionnement d'un problème est

$$\kappa = \sup \frac{\text{erreurs relatives résultat}}{\text{erreurs relatives données}},$$

avec les erreurs données $\rightarrow 0$.

CAS 1 : perturbations $\delta\mathbf{b}$ de \mathbf{b} ($\mathbf{x} + \delta\mathbf{x}$ est la solution du système perturbé)

$$\begin{aligned} A^T A(x + \delta\mathbf{x}) &= A^T(\mathbf{b} + \delta\mathbf{b}) \\ \Rightarrow A^T A \delta\mathbf{x} &= A^T \delta\mathbf{b} \quad (\text{soustraction de (1)}) \\ \Rightarrow \|\delta\mathbf{x}\|_2 &= \|A^\dagger \delta\mathbf{b}\|_2 \leq \|A^\dagger\|_2 \|\delta\mathbf{b}\|_2 \quad (\text{norme matricielle}) \end{aligned}$$

et donc

$$\kappa_{MC, \mathbf{b}} = \sup_{\|\delta\mathbf{b}\|} \frac{\|\delta\mathbf{x}\|_2 / \|\mathbf{x}\|_2}{\|\delta\mathbf{b}\|_2 / \|\mathbf{b}\|_2} \leq \kappa(A) \frac{\|\mathbf{b}\|_2}{\|A\|_2 \|\mathbf{x}\|_2} \leq \kappa(A) \frac{\|\mathbf{b}\|_2}{\|A\mathbf{x}\|_2} = \frac{\kappa(A)}{\cos(\theta)}$$

ANNEXE : CONDITIONNEMENT (DÉRIVATION)

Le problème aux moindres carrés est équivalent à

$$A^T A \mathbf{x} = A^T \mathbf{b}.$$

Le conditionnement d'un problème est

$$\kappa = \sup \frac{\text{erreurs relatives résultat}}{\text{erreurs relatives données}},$$

avec les erreurs données $\rightarrow 0$.

CAS 2 : perturbations δA de A ($\mathbf{x} + \delta \mathbf{x}$ est la solution du système perturbé)

$$(A + \delta A)^T (A + \delta A)(\mathbf{x} + \delta \mathbf{x}) = (A + \delta A)^T \mathbf{b}$$
$$\Rightarrow A^T A \delta \mathbf{x} + A^T \delta A \mathbf{x} + \underbrace{\delta A^T A \mathbf{x}}_{\text{le reste}} + \underbrace{\delta A^T \mathbf{b}}_{\text{second ordre}} = \delta A^T \mathbf{b} \quad (\text{soustraction de (1)})$$

$$\Rightarrow \|\delta \mathbf{x}\|_2 \leq \|A^\dagger\|_2 \|\delta A\|_2 \|\mathbf{x}\|_2 + \underbrace{\|(A^T A)^{-1}\|_2}_{\|A^\dagger\|_2^2} \underbrace{\|\delta A^T\|_2}_{\|\delta A\|_2} \underbrace{\|\mathbf{b} - A \mathbf{x}\|_2}_{\|\mathbf{r}\|}$$

et donc

$$\kappa_{MC,A} = \sup_{\|\delta A\|} \frac{\|\delta \mathbf{x}\|_2 / \|\mathbf{x}\|_2}{\|\delta A\|_2 / \|A\|_2} \leq \kappa(A) + \kappa(A)^2 \frac{\|\mathbf{r}\|_2}{\|A\|_2 \|\mathbf{x}\|_2} \leq \kappa(A) + \kappa(A)^2 \underbrace{\frac{\|\mathbf{r}\|_2}{\|A \mathbf{x}\|_2}}_{\tan(\theta)}$$